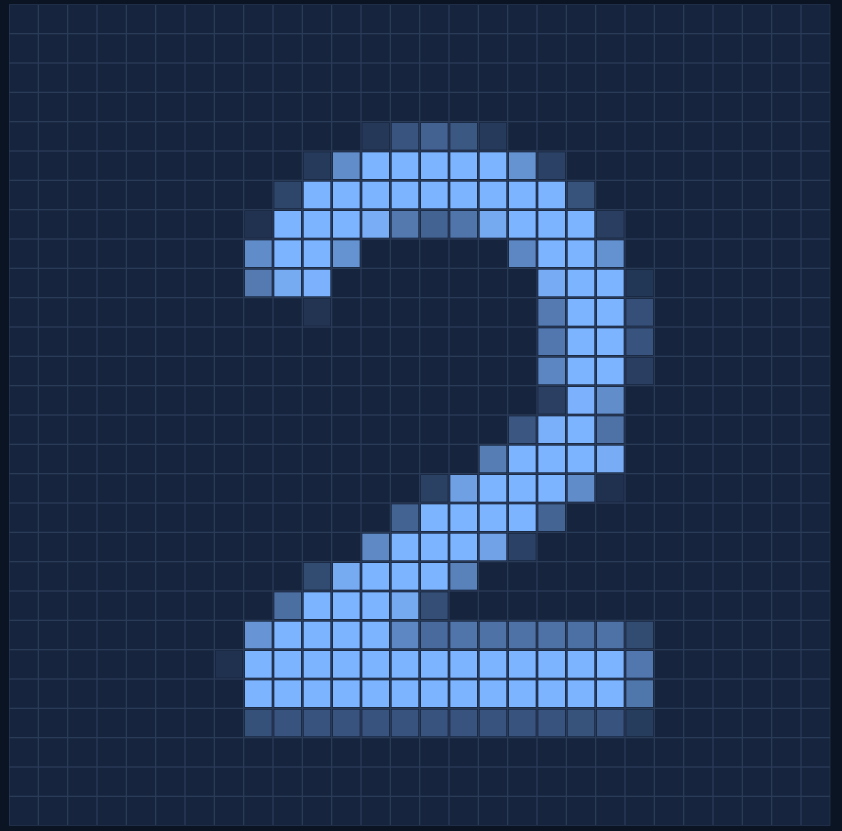
ECM963 · PESQUISA APLICADA COM IA

Dígito ao vivo na NPU

A predição continua certa quando a rede atrapalha?

Lucas Castanho Paganotto Carvalho · RA 22.00921-3



O TCC

Uma plataforma didática com NPU própria

- Processador RISC-V RV32I multiciclo, com extensão Zicsr
- NPU com arranjo sistólico 4×4
- FPGA Nexys A7-100T, a 100 MHz
- Rede para dígitos do MNIST: 6.810 parâmetros e 12.844 MACs por inferência



1.506 ciclos
cálculo da rede na NPU, cerca de 15 µs

9,2 ms
inferência completa, sendo 8,6 ms de comunicação serial

97,79%
acurácia na emulação, em 10.000 imagens

Fonte: artigos do TCC. Esses números não foram medidos nesta PoC.

O PROBLEMA

A resposta antiga pode chegar depois

O celular envia uma inferência a cada 0,2 s enquanto o usuário desenha.



Tempo	O que acontece	Na tela, sem proteção
0,0 s	Envia o desenho nº 6	Nada
0,2 s	Envia o desenho nº 9	Nada
0,5 s	Chega a resposta do nº 9	nº 9
0,8 s	Chega a resposta do nº 6	Volta para o nº 6

Tempos ilustrativos.

A PERGUNTA

A pergunta ficou mais precisa

INICIAL

Como o react-query permite mostrar ao vivo a predição da NPU enquanto o usuário desenha?



REFINADA

O react-query é **necessário** para manter a predição coerente com o desenho atual, com inferências a cada 0,2 s que voltam atrasadas, fora de ordem ou com erro, ou fetch com AbortController e um número de revisão bastam?

O MAPA DO TEMA

Mesmo pedido, duas IAs e a documentação

CHATGPT

Número de revisão obrigatório, comparação entre useQuery e useMutation, alerta sobre o Expo Go no SDK 58

GEMINI

Disse que o react-query cancela automaticamente

DOCUMENTAÇÃO · DECIDE

Confirmou o AbortSignal e desmentiu o cancelamento automático por padrão

As duas IAs apontaram **fetch com AbortController** como caminho direto.

A PERGUNTA

Por que a pergunta foi refinada

O cache do react-query ajuda pouco, porque a predição muda a cada traço	ChatGPT
Em um uso tão pequeno, ele pode acrescentar complexidade sem necessidade	Gemini
Ele não cancela sozinho: é preciso usar o signal	Documentação
Cancelar pode não bastar: uma resposta antiga ainda pode chegar	ChatGPT, hipótese a testar

MINHA CONCLUSÃO

A pergunta inicial já assumia que o react-query era a solução. A dúvida real era se ele era necessário, então a nova pergunta admite “não”, e um teste no aparelho decide.

A ESCOLHA

Alternativas consideradas

Opção	Serve para	Expo Go	Decisão
fetch + AbortController	Enviar e cancelar requisições, com revisão feita à mão	Testado no iPhone	Escolhida: sem dependências
Hook próprio useFetch	Organizar a mesma lógica	Não testado	Não usada: há uma tela só
react-query	Cache, novas tentativas e dados remotos	Não testado	Plano B: não foi necessário

COMO FUNCIONA

Do traço à predição



APP

Expo SDK 58, no iPhone, pelo Expo Go

O APP ENVIA

Os traços e o número de revisão do desenho

O SERVIDOR DEVOLVE

Dígito, confiança, origem e a mesma revisão

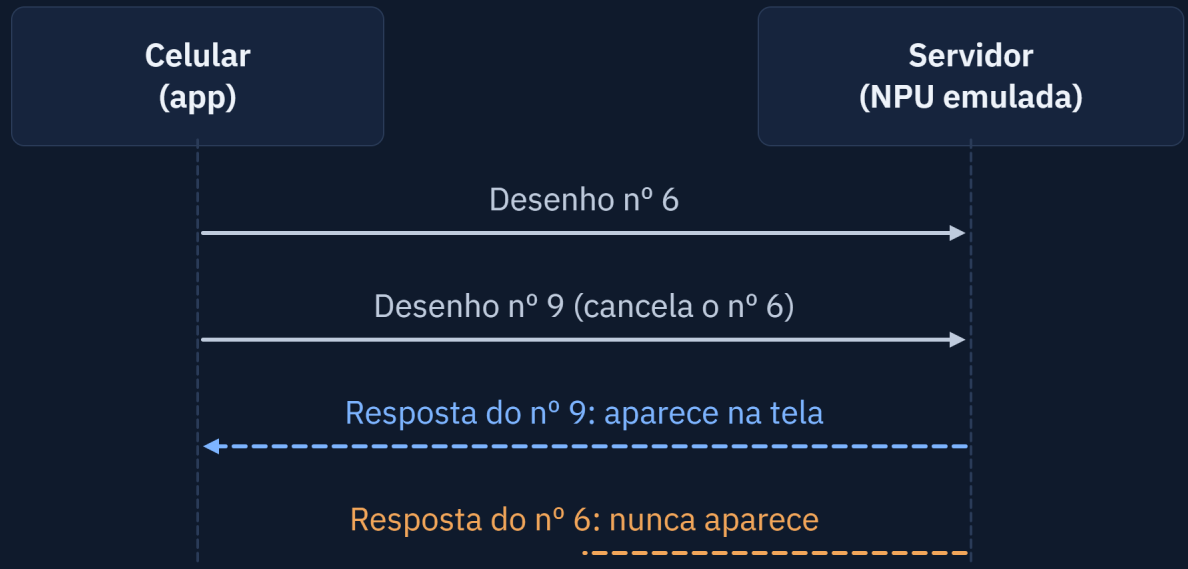
EMULAÇÃO

Mesma conta em inteiros de 8 bits, com o arredondamento da PPU

A PROTEÇÃO

A proteção tem três partes

1. **Cancelar:** cada novo envio cancela a requisição anterior.
2. **Comparar a revisão:** só entra na tela a resposta mais nova do que a exibida.
3. **Identificar o desenho:** limpar muda um identificador interno, e respostas do desenho anterior são ignoradas.



Por que não basta cancelar: uma resposta pode já estar chegando quando o cancelamento acontece.

DEMONSTRAÇÃO

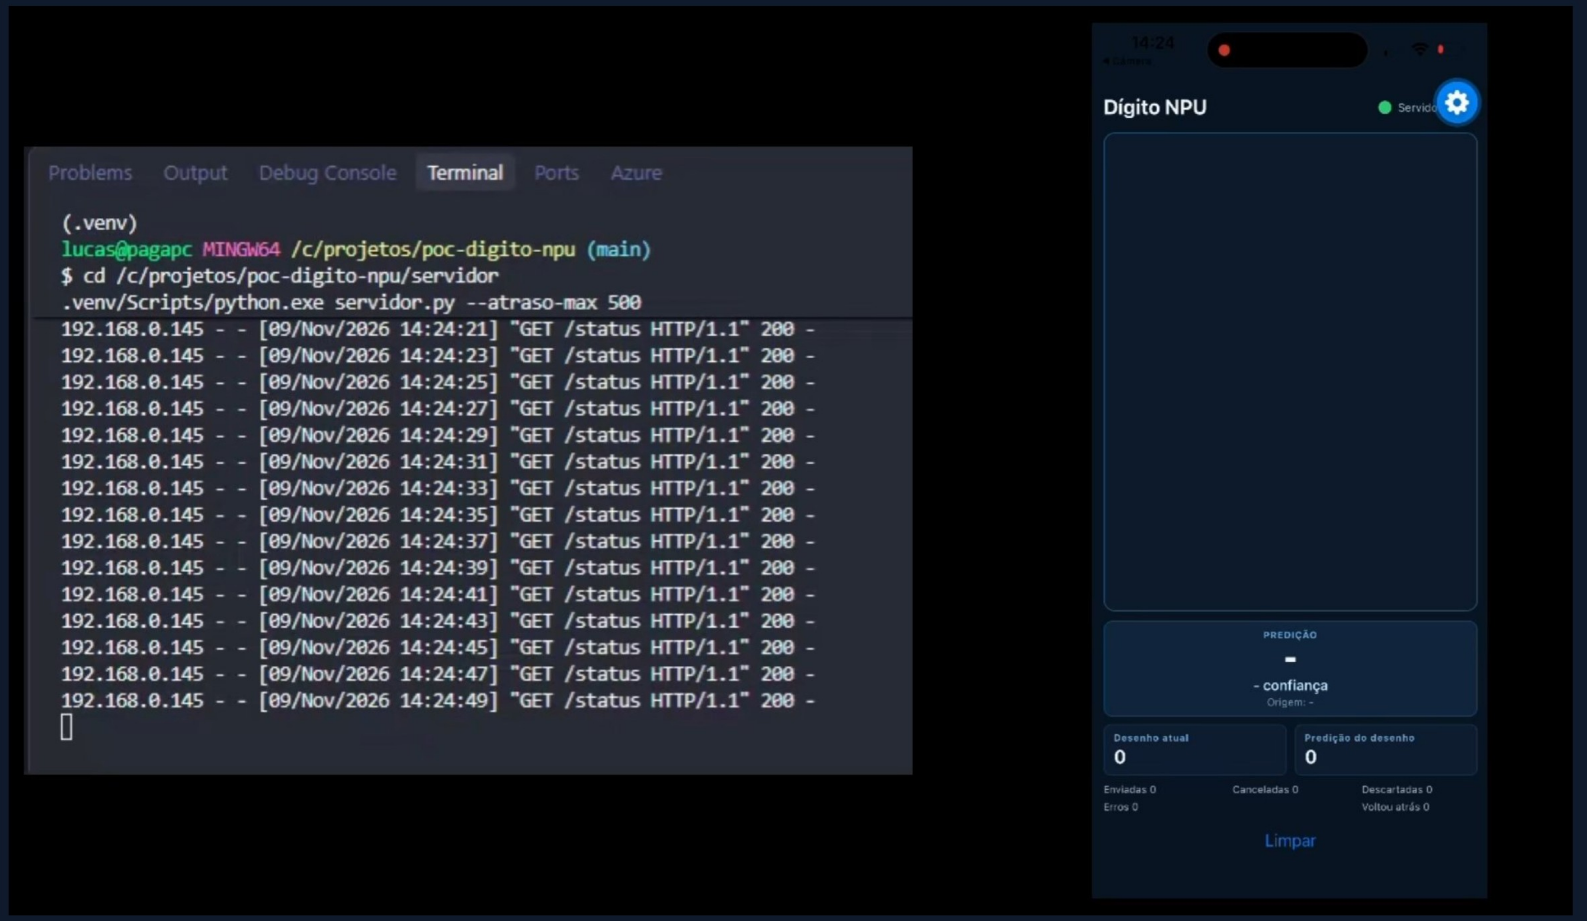
Demonstração, critério por critério

- O traço acompanha o dedo enquanto as inferências rodam
- “Predição do desenho” nunca diminui
- Até 1 s depois de parar, ele fica igual a “Desenho atual”
- Depois de limpar, nada reaparece
- Servidor desligado: LED vermelho em até 4 s, lousa bloqueada e botão Reconectar

Servidor com atraso aleatório de até 0,5 s.

DEMONSTRAÇÃO

Demonstração, critério por critério



Servidor com atraso aleatório de até 0,5 s.

RESULTADO

Antes e depois: o fetch bastou nessa condição

Condição: atraso aleatório de 0 a 0,5 s, em 10 desenhos, em um iPhone.

Medida	Sem proteção	Com proteção
Resposta antiga sobrescreveu a nova	Até 8 vezes em um desenho	0
Depois de limpar, com atraso de 2 s	A predição reapareceu	Nada apareceu
Requisições canceladas, em três desenhos	Não havia cancelamento	5, 2 e 7
Número igual ao do desenho, depois de parar	Não medido	Em até 1 s

> **Resposta:** nessa condição, o react-query não foi necessário. Ele não foi testado, então não dá para dizer que é pior.

ONDE A IA ERROU

7 erros registrados

GEMINI

Veio: o react-query cancela automaticamente

Como percebi: lendo Query Cancellation

O certo: por padrão não cancela: é preciso usar o signal

COPILOT

Veio: removeu um import e disse que o modo placa continuaria compatível

Como percebi: revisando o diff

O certo: manter o import: o erro só apareceria com a placa ligada

COPILOT

Veio: contador de cancelamentos sempre em 0

Como percebi: o valor era impossível com esse atraso

O certo: identificar o cancelamento pelo signal.aborted

COPILOT

Veio: apagava as mensagens de erro a cada consulta ao servidor

Como percebi: testando no celular

O certo: apagar só a mensagem de falha de comunicação

Os outros 3 estão no próximo slide.

ONDE A IA ERROU

Os outros 3 erros

COPILOT

Veio: consultou a página do Expo Network quando pedi a documentação sobre requisições

Como percebi: comparando o assunto da página com o pedido

O certo: a página trata do estado da rede do aparelho e não ensina a fazer requisições

CHATGPT

Veio: disse que useMutation exige controle próprio contra respostas antigas

Como percebi: lendo a página de Mutations

O certo: callbacks do mutate só rodam para a última chamada

COPILOT

Veio: não zerou a referência do intervalo, e o LED parava de atualizar depois de um Fast Refresh

Como percebi: testando no celular e lendo o código

O certo: zerar a referência na limpeza do efeito

Lista completa no PESQUISA.md, no repositório.

FECHAMENTO

Limites e próximos passos

LIMITES

- A inferência rodou em emulação, e o modo placa não foi executado
- Os tempos medidos não incluem a FPGA real
- Um único iPhone, 10 desenhos e atrasos de até 0,5 s
- A documentação diz que o Expo Go da App Store para no SDK 54, mas o SDK 58 abriu no aparelho, sem explicação encontrada

O QUE MUDA NO TCC

- Testar com a placa real e medir a latência do celular até a NPU
- Usar o app na demonstração da plataforma, como cliente sem fio

REFERÊNCIAS

Fontes e ferramentas

DOCUMENTAÇÃO

- TanStack Query, Query Cancellation e Mutations: tanstack.com/query
- React Native, Networking e PanResponder: reactnative.dev/docs
- MDN, AbortController: developer.mozilla.org
- Expo, versões do Expo Go e sign-in: docs.expo.dev/troubleshooting
- Expo, react-native-svg e safe-area-context: docs.expo.dev/versions/v58.0.0

FERRAMENTAS DE IA

- GitHub Copilot com o MCP do Expo (construção)
- ChatGPT e Gemini (mapa do tema)
- Claude Code (planejamento, prompts, textos e revisão de diffs)

REPOSITÓRIO

`github.com/lucaspaga/poc-digito-npu`